

06

강

R 컴퓨팅

확장된 R 데이터 구조 (1)

통계·데이터과학과 장영재 교수

학습목차

1 새로운 데이터 분석 패러다임 : Tidyverse

2 Tibble : 개선된 데이터 프레임

3 실습하기

학습목표

- 1 Tidyverse 생태계의 개념과 주요 패키지를 이해한다.
- 2 tibble의 특징과 전통적인 데이터 프레임과의 차이점을 설명할 수 있다.
- 3 tibble을 이용하여 생성된 데이터 구조를 이해할 수 있다.
- 4 Tibble 데이터 프레임을 전통적 데이터 프레임 형태로 변환할 수 있다.



01

새로운 데이터 분석 패러다임 : Tidyverse

1. 새로운 데이터 분석 패러다임 : Tidyverse

- ▶ R은 기본적인 데이터 구조를 다루는 과정에서 다소 불편
 - 기본 함수들이 직관적이지 않고, 각 데이터 구조마다 해당 데이터를 편집하기 위한 함수를 개별적으로 익히거나 반복문 등을 직접 작성해야 하기 때문
 - 이러한 문제의식을 바탕으로 R에서 데이터 과학을 위해 자주 쓰이는 여러 패키지를 묶어 제공하는 통합 생태계 Tidyverse가 등장 : 데이터 과학을 위해 자주 쓰이는 패키지를 결합 + tidy data(정돈된 데이터)

www.tidyverse.org

1. 새로운 데이터 분석 패러다임 : Tidyverse

▶ Tidyverse 설치하기

- `install.packages("tidyverse")`

- `library(tidyverse)`

<Tidyverse 핵심 패키지(core packages)>

<code>dplyr</code>	데이터 프레임의 효율적 편집과 가공
<code>ggplot2</code>	데이터 시각화를 위한 강력한 그래픽 도구
<code>tidyr</code>	데이터를 깔끔한(tidy) 구조로 변환
<code>readr</code>	CSV 등 직사각형 데이터를 빠르게 읽기
<code>tibble</code>	개선된 형태의 데이터 프레임 제공
<code>stringr</code>	문자열 처리 기능 강화
<code>forcats</code>	범주형 데이터(factor) 다루기
<code>purrr</code>	함수형 프로그래밍 지원 (반복 처리 단순화)
<code>lubridate</code>	날짜·시간 데이터 처리

02

Tibble : 개선된 데이터 프레임

2. Tibble : 개선된 데이터 프레임

▶ tibble은 기존 데이터 프레임의 한계를 극복하기 위해 등장

- 데이터를 더 깔끔하고 직관적으로 다루기 위해 기존 데이터 프레임을 개선한 구조
- 사용자 친화성이 특징이며 데이터 출력 시 다양한 정보를 포함하여 편의를 제공

 사용자 지정을 보존하여 직관적이고 효율적인 데이터 분석을 지원

▶ 전통적 데이터 프레임과의 차이

- tibble은 화면 크기에 맞게 일부 행과 열만 요약하여 출력
- 사용자가 입력한 열 이름을 그대로 유지함에 따라 변수명 관리가 훨씬 단순하고 직관적
- 문자열을 factor로 변환하여 저장하지 않고 문자열을 기본적으로 character로 처리
- 직관적이고 단순화된 규칙을 제공하기 때문에 처음 배우는 사용자도 쉽게 익힐 수 있음

2. Tibble : 개선된 데이터 프레임

▶ tibble 생성과 변환 (tibble(), as_tibble())

- tibble은 직관적이고 단순한 문법을 제공하며, 특히 tidyverse 패키지와 함께 활용할 때 유용

예제 4-1 학생 데이터를 tibble로 생성한 예시

```
> tb1 <- tibble(학번 = 101:103, 국어 = c(85, 90, 78), 수학 = c(92, 88, 81))
```

```
> tb1
```

```
# A tibble: 3 × 3
```

```
학번 국어 수학
```

```
<int> <dbl> <dbl>
```

```
1 101 85 92
```

```
2 102 90 88
```

```
3 103 78 81
```

```
> tb1 + 5
```

```
학번 국어 수학
```

```
1 106 90 97
```

```
2 107 95 93
```

```
3 108 83 86
```

2. Tibble : 개선된 데이터 프레임

예제 4-2 학생 데이터를 tribble로 생성한 예시

```
> tb2 <- tribble(  
+ ~학번, ~이름, ~합격여부,  
+ 201, "Alice", TRUE,  
+ 202, "Bob", FALSE,  
+ 203, "Clare", TRUE  
+ )  
>
```

2. Tibble : 개선된 데이터 프레임

```
> tb2
```

```
# A tibble: 3 × 3
```

```
학번 이름 합격여부
```

```
<dbl> <chr> <lgl>
```

```
1 201 Alice TRUE
```

```
2 202 Bob FALSE
```

```
3 203 Clare TRUE
```

- tibble() 함수가 열 단위로 데이터를 정의하는 방식이라면,
tribble() 함수는 보다 직관적인 행 단위 입력(row-wise input) 방식을 제공

2. Tibble : 개선된 데이터 프레임

- tidyverse 패키지에 포함된 내장 데이터 중 diamonds의 예시

```
> diamonds
```

```
# A tibble: 53,940 × 10
```

```
carat cut color clarity depth table price x y z
```

```
<dbl> <ord> <ord> <ord> <dbl> <dbl> <int> <dbl> <dbl> <dbl>
```

```
1 0.23 Ideal E SI2 61.5 55 326 3.95 3.98 2.43
```

```
2 0.21 Premium E SI1 59.8 61 326 3.89 3.84 2.31
```

```
3 0.23 Good E VS1 56.9 65 327 4.05 4.07 2.31
```

```
4 0.29 Premium I VS2 62.4 58 334 4.20 4.23 2.63
```

```
5 0.31 Good J SI2 63.3 58 335 4.34 4.35 2.75
```

```
# ... with 53,935 more rows
```

2. Tibble : 개선된 데이터 프레임

```
> print(diamonds, n = 10, width = Inf)
# A tibble: 53,940 × 10
  carat cut    color clarity depth table price x   y   z
<dbl> <ord> <ord> <ord> <dbl> <dbl> <int> <dbl> <dbl> <dbl>
1  0.23 Ideal E    SI2    61.5  55   326   3.95   3.98   2.43
2  0.21 Premium E    SI1    59.8  61   326   3.89   3.84   2.31
3  0.23 Good  E    VS1    56.9  65   327   4.05   4.07   2.31
4  0.29 Premium I    VS2    62.4  58   334   4.2    4.23   2.63
5  0.31 Good  J    SI2    63.3  58   335   4.34   4.35   2.75
6  0.24 Very Good J    VVS2    62.8  57   336   3.94   3.96   2.48
7  0.24 Very Good I    VVS1    62.3  57   336   3.95   3.98   2.47
8  0.26 Very Good H    SI1    61.9  55   337   4.07   4.11   2.53
9  0.22 Fair  E    VS2    65.1  61   337   3.87   3.78   2.49
10 0.23 Very Good H    VS1    59.4  61   338   4    4.05   2.39
# i 53,930 more rows
# i Use `print(n = ...)` to see more rows
```

2. Tibble : 개선된 데이터 프레임

- 기존 데이터 프레임을 tibble로 변환할 때는 `as_tibble()`을,
tibble을 기존 데이터 프레임으로 변환하려면 `as.data.frame()`을 사용

```
> iris1 <- as_tibble(iris)
```

```
> iris1
```

```
# A tibble: 150 × 5
```

```
Sepal.Length Sepal.Width Petal.Length Petal.Width Species
```

```
<dbl> <dbl> <dbl> <dbl> <fct>
```

```
1 5.1 3.5 1.4 0.2 setosa
```

```
2 4.9 3 1.4 0.2 setosa
```

```
3 4.7 3.2 1.3 0.2 setosa
```

```
4 4.6 3.1 1.5 0.2 setosa
```

```
5 5 3.6 1.4 0.2 setosa
```

```
# ... with 145 more rows
```

2. Tibble : 개선된 데이터 프레임

예제 4-4 예제 4-1의 tb1 tibble 데이터 프레임을 전통적인 데이터 프레임으로 변환

```
# 예제 4-1 tibble 생성
```

```
> library(tibble)
```

```
> tb1 <- tibble(
```

```
+ 학번 = 101:103,
```

```
+ 국어 = c(85, 90, 78),
```

```
+ 수학 = c(92, 88, 81)
```

```
+)
```

```
# tibble → 전통적 데이터 프레임 변환
```

```
> df1 <- as.data.frame(tb1)
```

2. Tibble : 개선된 데이터 프레임

변환된 데이터 프레임 출력

```
> df1
```

```
학번 국어 수학
```

```
1 101 85 92
```

```
2 102 90 88
```

```
3 103 78 81
```

데이터 구조 확인

```
> str(df1)
```

```
'data.frame': 3 obs. of 3 variables:
```

```
$ 학번: int 101 102 103
```

```
$ 국어: num 85 90 78
```

```
$ 수학: num 92 88 81
```

- 행 이름(rownames)으로 구성된 데이터는 rownames_to_column() 함수를 이용해 별도의 변수로 바꿀 수 있음

2. Tibble : 개선된 데이터 프레임

예제 4-5 R 내장 데이터인 mtcars 데이터에서 행 이름을 변수로 바꾸어 tibble로 변환

```
> mtcars1 <- as_tibble(rownames_to_column(mtcars))
> mtcars1
# A tibble: 32 × 12
  rowname mpg  cyl  disp  hp  drat  wt  qsec vs  am  gear carb
<chr> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
1 Mazda RX4 21 6 160 110 3.9 2.62 16.5 0 1 4 4
2 Mazda RX4 Wag 21 6 160 110 3.9 2.88 17.0 0 1 4 4
3 Datsun 710 22.8 4 108 93 3.85 2.32 18.6 1 1 4 1
4 Hornet 4 Dr~ 21.4 6 258 110 3.08 3.22 19.4 1 0 3 1
5 Hornet Spor~ 18.7 8 360 175 3.15 3.44 17.0 0 0 3 2
# ... with 27 more rows
```

2. Tibble : 개선된 데이터 프레임

▶ tibble 출력 방식의 장점

- 한눈에 구조를 이해할 수 있도록 설계
- 모든 데이터를 한꺼번에 보여주지 않고 화면 크기에 맞추어 일부 행과 열만 요약하여 제시
- <dbl>, <chr>와 같은 자료형이 함께 표시되어, 변수의 성격을 직관적으로 확인

03

실습하기

07강

다음시간안내 ▶▶▶

확장된 R데이터구조 (2)