

07

강

R 컴퓨팅

확장된 R 데이터 구조 (2)

통계·데이터과학과 장영재 교수

학습목차

1 데이터 불러오기와 저장하기 (readr 패키지)

2 데이터 다루기 (dplyr 패키지)

3 실습하기

학습목표

- 1 readr의 개념 및 활용법을 이해할 수 있다.
- 2 readr을 이용하여 데이터를 불러올 수 있다.
- 3 dplyr의 개념 및 활용법을 이해할 수 있다.
- 4 dplyr을 이용하여 데이터를 선택, 가공, 요약할 수 있다.



01

데이터 불러오기와 저장하기 (readr 패키지)

1. 데이터 불러오기와 저장하기 (readr 패키지)

▶ read_csv(): 콤마(,)로 구분된 CSV 파일 읽기

- CSV(Comma-Separated Values) 파일은 데이터 분석에서 가장 흔히 사용되는 형식
- read.csv() 함수와의 차이점은 콤마(,)로 구분된 데이터를 읽고 tibble 형태로 불러온다는 차이

예제 4-6 외부 CSV 파일이 id,name,score라는 변수들로 이루어진 header를 가지고 있고
각 행은 101,Alice,85과 102,Bob,90 및 103,Clare,88 로 이루어져 있다고 할 때,
이를 read_csv() 함수를 이용하여 불러오기

```
id,name,score
101,Alice,85
102,Bob,90
103,Clare,88
```

<students.csv 파일>

1. 데이터 불러오기와 저장하기 (readr 패키지)

```
> library(readr)
```

```
> students <- read_csv("c:/data/students.csv")
```

```
> students
```

```
# A tibble: 3 × 3
```

```
id name score
```

```
<dbl> <chr> <dbl>
```

```
1 101 Alice 85
```

```
2 102 Bob 90
```

```
3 103 Clare 88
```

▶ `read_tsv( )`: 탭(tab)으로 구분된 데이터 읽기

- TSV(Tab-Separated Values) 파일은 데이터를 저장할 때 각 항목을 탭(tab) 문자로 구분하는 형식
- CSV 파일이 콤마(,)를 기준으로 항목을 나누는 것과 달리, TSV 파일은 탭 문자(\t)를 기준으로 구분

1. 데이터 불러오기와 저장하기 (readr 패키지)

예제 4-7 외부 TSV 파일 students.tsv가 다음과 같이 탭으로 구분되어 있는 열로 구성된 데이터 세트일 때, read_tsv() 함수를 이용하여 불러오기(id, name, score는 변수명을 나타내는 header)

id	name	score
101	Alice	85
102	Bob	90
103	Clare	88

```
> library(readr)
```

```
> students <- read_tsv("students.tsv")
```

```
> students
```

```
# A tibble: 3 × 3
```

```
id name score
```

```
<dbl> <chr> <dbl>
```

```
1 101 Alice 85
```

```
2 102 Bob 90
```

```
3 103 Clare 88
```

1. 데이터 불러오기와 저장하기 (readr 패키지)

▶ read_delim() : 임의 구분자(delimiter) 지정

- read_delim() 함수를 사용하면 CSV, TSV 외 다양한 기호의 구분자로 이루어진 데이터를 불러올 수 있음
- 사용자가 직접 구분자(delimiter)를 지정

예제 4-8 외부 데이터 파일 students.txt가 다음과 같이 세미콜론(;) 기호로 구분되어 있을 때 이 파일을 불러오기

```
id;name;score
101;Alice;85
102;Bob;90
103;Clare;88
```

<students.txt 파일>

```
> library(readr)
> students <- read_delim("students.txt", delim=";")
> students
# A tibble: 3 × 3
  id name score
  <dbl> <chr> <dbl>
1 101 Alice 85
2 102 Bob 90
3 103 Clare 88
```


1. 데이터 불러오기와 저장하기 (readr 패키지)

▶ read_table() : 공백으로 구분된 파일 읽기

- read_table() 함수는 공백(space)을 구분 기호로 사용하는 텍스트 파일을 불러올 때 유용(콤마(.)나 탭(tab)이 아님)
- 공백의 개수와 상관없이 데이터를 올바르게 분리하여 읽어들이м

예제 4-9 공백으로 구분된 외부 데이터 파일 students_space.txt가 다음과 같을 때, read_table() 함수로 불러오기
(두 번째 행의 Bob과 90 사이는 세 칸의 공백으로 이루어져 있음)

```
> library(readr)
```

```
> students <- read_table("students_space.txt")
```

```
> students
```

```
# A tibble: 3 × 3
```

```
id name score
```

```
<dbl> <chr> <dbl>
```

```
1 101 Alice 85
```

```
2 102 Bob 90
```

```
3 103 Clare 88
```

1. 데이터 불러오기와 저장하기 (readr 패키지)

▶ 데이터 저장하기 : `write_csv()`, `write_tsv()`, `write_delim()`

- 데이터 프레임이나 **tibble**를 외부 파일로 내보내는 기능을 수행
- readr 패키지는 `read_*()` 계열 함수와 짝을 이루어, `write_*()` 계열의 쓰기 함수들을 제공
- 공통적인 특징은 단순하고 일관된 문법을 제공한다는 점

예제 4-10 R에서 간단한 tibble 데이터를 생성하고 이를 CSV, TSV, 세미콜론 구분 형태의 각각의 외부 파일로 저장

```
> library(readr)

> students <- tibble(
+ id = c(101, 102, 103),
+ name = c("Alice", "Bob", "Clare"),
+ score = c(85, 90, 88)
+)
```

1. 데이터 불러오기와 저장하기 (readr 패키지)

CSV 파일로 저장

```
> write_csv(students, "students.csv")
```

TSV 파일로 저장

```
> write_tsv(students, "students.tsv")
```

세미콜론(;) 구분자로 저장

```
> write_delim(students, "students_semicolon.txt", delim = ";")
```

02

데이터 다루기 (dplyr 패키지)

2. 데이터 다루기 (dplyr 패키지)

▶ dplyr 의 특징

- 직관적인 문법과 체계적인 함수 구성을 제공
- 선택(select), 필터링(filter), 정렬(arrange), 요약(summarise), 변환(mutate)과 같은 기본적인 작업을 간결하게 수행
- 파이프 연산자(%>%)와 함께 활용하면, 여러 단계의 데이터 처리 과정을 자연스럽게 연결

▶ 특정 조건을 만족하는 행의 추출 : filter()

- tibble 데이터에서 특정 조건을 만족하는 행(row)을 추출할 때 사용

📖 하나의 조건 또는 여러 개의 조건을 조합하여 동시 적용 가능

📖 복잡한 데이터세트에서 필요한 부분만 남겨서 분석할 수 있음

2. 데이터 다루기 (dplyr 패키지)

예제 4-11 dplyr 패키지에 내장된 tibble 데이터 프레임 storms에서 풍속이 100 이상이면서 기압이 950 이하인 강력한 태풍의 기록만을 추출

```
> library(dplyr)
```

```
# storms 데이터에서 풍속이 100 이상이고 기압이 950 이하인 경우만 추출
```

```
> sstorms <- filter(storms, wind >= 100, pressure <= 950)
```

```
> sstorms
```

2. 데이터 다루기 (dplyr 패키지)

예제 4-11 dplyr 패키지에 내장된 tibble 데이터 프레임 storms에서 풍속이 100 이상이면서 기압이 950 이하인 강력한 태풍의 기록만을 추출

```
hour lat long status category wind pressure
```

```
<chr> <dbl> <dbl> <int> <dbl> <dbl> <dbl> <fct> <dbl> <int> <int>
```

```
1 Gladys 1975 10 2 6 32.9 -72.1 hurricane 3 110 942
```

```
2 Gladys 1975 10 2 12 35.3 -69.8 hurricane 4 120 939
```

```
3 Gladys 1975 10 2 18 37.8 -67 hurricane 4 120 939
```

```
4 Gladys 1975 10 3 0 40.8 -62.6 hurricane 3 110 950
```

```
5 Anita 1977 9 1 18 25.2 -95.5 hurricane 3 110 945
```

```
6 Anita 1977 9 2 0 24.6 -96.2 hurricane 5 140 931
```

```
7 Anita 1977 9 2 6 24.2 -97.1 hurricane 5 150 926
```

```
8 Anita 1977 9 2 12 23.7 -98 hurricane 4 120 940
```

```
9 Greta 1978 9 18 6 15.8 -84.3 hurricane 4 115 947
```

```
10 David 1979 8 28 0 12.2 -52.9 hurricane 4 115 947
```

2. 데이터 다루기 (dplyr 패키지)

▶ 특정 조건을 만족하는 열의 추출 : `select()`

- tibble 데이터 프레임에서 원하는 변수(열, column)만 지정하여 추출할 때 사용
- `filter()` 함수가 조건에 맞는 특정 관측치(행)를 선택하는 데 중점을 두는 반면, `select()` 함수는 전체 행은 그대로 두고 특정 변수만 남겨 두는 방식으로 작동

2. 데이터 다루기 (dplyr 패키지)

예제 4-12 dplyr 패키지에 내장된 tibble 데이터 프레임 storms에서
name, year, lat, long, wind, pressure 변수만 추출

```
> library(dplyr)
```

```
# storms 데이터에서 name, year, lat, long, wind, pressure 변수만 추출
```

2. 데이터 다루기 (dplyr 패키지)

```
> select(storms, name, year, lat, long, wind, pressure)
```

```
# A tibble: 19,537 × 6
```

```
name year lat long wind pressure
```

```
<chr> <dbl> <dbl> <dbl> <int> <int>
```

```
1 Amy 1975 27.5 -79 25 1013
```

```
2 Amy 1975 28.5 -79 25 1013
```

```
3 Amy 1975 29.5 -79 25 1013
```

```
4 Amy 1975 30.5 -79 25 1013
```

```
5 Amy 1975 31.5 -78.8 25 1012
```

```
6 Amy 1975 32.4 -78.7 25 1012
```

```
7 Amy 1975 33.3 -78 25 1011
```

2. 데이터 다루기 (dplyr 패키지)

```
8 Amy 1975 34 -77 30 1006
```

```
9 Amy 1975 34.4 -75.8 35 1004
```

```
10 Amy 1975 34 -74.8 40 1002
```

```
# i 19,527 more rows
```

```
# i Use `print(n = ...)` to see more rows
```

▶ 새로운 변수의 생성 및 추가 : mutate()

- 기존 데이터 프레임에 새로운 변수를 추가하거나 기존 변수를 변형하여 새로운 열을 생성
- filter()가 특정 행을, select()가 특정 열을 선택하는 데 주로 사용된다면,
mutate()는 기존 데이터를 기반으로 새로운 정보를 계산하여 확장하는 데 사용

2. 데이터 다루기 (dplyr 패키지)

예제 4-13 dplyr 패키지에 내장된 tibble 데이터 프레임 storms에서 풍속(wind)과 중심 기압(pressure) 변수를 활용해 단순한 지표 생성(태풍의 풍속에서 중심 기압의 1/10 값을 뺀 값을 새로운 변수 storm_index로 정의)하여 추가

```
> library(dplyr)
> storms2 <- mutate(storms, storm_index = wind - pressure/10)
> select(storms2, name, year, wind, pressure, storm_index)
```

2. 데이터 다루기 (dplyr 패키지)

```
# A tibble: 19,537 × 5
```

```
name year wind pressure storm_index
```

```
<chr> <dbl> <int> <int> <dbl>
```

```
1 Amy 1975 25 1013 -76.3
```

```
2 Amy 1975 25 1013 -76.3
```

```
3 Amy 1975 25 1013 -76.3
```

```
4 Amy 1975 25 1013 -76.3
```

```
5 Amy 1975 25 1012 -76.2
```

```
6 Amy 1975 25 1012 -76.2
```

```
7 Amy 1975 25 1011 -76.1
```

```
8 Amy 1975 30 1006 -70.6
```

2. 데이터 다루기 (dplyr 패키지)

```
9 Amy 1975 35 1004 -65.4
```

```
10 Amy 1975 40 1002 -60.2
```

```
# i 19,527 more rows
```

```
# i Use `print(n = ...)` to see more rows
```

2. 데이터 다루기 (dplyr 패키지)

▶ 데이터의 정렬 : arrange()

- tibble 데이터 프레임 내에서 특정 변수를 기준으로 관측치를 정렬하는 기능을 수행
- 기본적으로는 오름차순 정렬이 적용
- 작은 값 순서로 보고자 할 경우에는 desc() 함수를 함께 사용
- 데이터의 전반적인 분포를 한눈에 파악하거나, 상위·하위 몇 개의 극단값을 빠르게 확인하는 데 매우 유용

2. 데이터 다루기 (dplyr 패키지)

예제 4-14 dplyr 패키지에 내장된 tibble 데이터 프레임 storms에서 풍속(wind) 변수를 기준으로 데이터를 정렬

```
> library(dplyr)
> # 풍속(wind)을 기준으로 오름차순 정렬
➤ arrange(storms, wind)
```

```
# A tibble: 19,537 × 13
```

```
name year month day hour lat long status category wind pressure
```

```
<chr> <dbl> <dbl> <int> <dbl> <dbl> <dbl> <fct> <dbl> <int> <int>
```

```
1 Bonnie 1986 6 28 6 36.5 -91.3 tropica... NA 10 1013
```

```
2 Bonnie 1986 6 28 12 37.2 -90 tropica... NA 10 1012
```

```
3 Charley 1986 8 13 12 30.1 -84 subtrop... NA 10 1009
```

```
4 Charley 1986 8 13 18 30.8 -84 subtrop... NA 10 1012
```


2. 데이터 다루기 (dplyr 패키지)

```
5 Charley 1986 8 14 0 31.4 -83.6 subtrop... NA 10 1013
6 Charley 1986 8 14 6 32 -83.1 subtrop... NA 10 1014
7 Charley 1986 8 14 12 32.5 -82.5 subtrop... NA 10 1015
8 Charley 1986 8 14 18 32.4 -82 subtrop... NA 10 1015
9 AL031987 1987 8 16 18 30.9 -83.2 tropica... NA 10 1014
10 AL031987 1987 8 17 0 31.4 -82.9 tropica... NA 10 1015
# i 19,527 more rows
# i 2 more variables: tropicalstorm_force_diameter <int>,
# hurricane_force_diameter <int>
# i Use `print(n = ...)` to see more rows
```

2. 데이터 다루기 (dplyr 패키지)

> # 풍속(wind)을 기준으로 내림차순 정렬

> arrange(storms, desc(wind))

A tibble: 19,537 × 13

name year month day hour lat long status category wind pressure

<chr> <dbl> <dbl> <int> <dbl> <dbl> <dbl> <fct> <dbl> <int> <int>

1 Allen 1980 8 7 18 21.8 -86.4 hurricane 5 165 899

2 Gilbert 1988 9 14 0 19.7 -83.8 hurricane 5 160 888

3 Wilma 2005 10 19 12 17.3 -82.8 hurricane 5 160 882

4 Dorian 2019 9 1 16 26.5 -77 hurricane 5 160 910

5 Dorian 2019 9 1 18 26.5 -77.1 hurricane 5 160 910

6 Allen 1980 8 5 12 15.9 -70.5 hurricane 5 155 932

7 Allen 1980 8 7 12 21 -84.8 hurricane 5 155 910

8 Allen 1980 8 8 0 22.2 -87.9 hurricane 5 155 920

9 Allen 1980 8 9 6 25 -94.2 hurricane 5 155 909

2. 데이터 다루기 (dplyr 패키지)

```
> # 풍속(wind)을 기준으로 내림차순 정렬
10 Gilbert 1988 9 14 6 19.9 -85.3 hurricane 5 155 889
# i 19,527 more rows
# i 2 more variables: tropicalstorm_force_diameter <int>,
# hurricane_force_diameter <int>
# i Use `print(n = ...)` to see more rows
```

2. 데이터 다루기 (dplyr 패키지)

예제 4-15 dplyr 패키지에 내장된 tibble 데이터 프레임 storms에 관해서 파이프 연산자를 이용하여 분석한 사례 1

```
> library(dplyr)
```

```
> # storms 데이터의 wind 변수의 평균값
```

```
> storms$wind %>% mean
```

```
[1] 50.04939
```

```
> # storms 데이터의 wind 값 중 임의로 5개 추출
```

```
> storms$wind %>% sample(5)
```

```
[1] 30 35 30 100 40
```

```
> storms$wind %>% sample(5)
```

```
[1] 30 20 40 25 105
```

```
> storms$wind %>% sample(5)
```

```
[1] 155 30 45 55 50
```

2. 데이터 다루기 (dplyr 패키지)

▶ 주요 통계량의 산출 : summarize()

- 기존의 데이터 프레임에서 사용한 summary() 함수와 유사
- summarize() 함수는 사용자가 지정한 조건과 계산식을 직접 적용할 수 있다는 점에서 보다 유연
- summarize() 함수는 맞춤형 요약도 가능
- summary() 함수는 데이터의 전체적 특성을 한눈에 파악하는 데 적합하고, summarize() 함수는 분석 목적에 맞춘 세밀한 통계 계산에 유리

2. 데이터 다루기 (dplyr 패키지)

예제 4-16 dplyr 패키지에 내장된 tibble 데이터 프레임에서 storms에 관해서 summary() 함수와 summarize() 함수를 이용하여 주요 통계량을 산출

```
> library(dplyr)
```

```
> summary(storms)
```

```
name year month day
```

```
Length:19537 Min. :1975 Min. : 1.000 Min. : 1.00
```

```
Class :character 1st Qu.:1994 1st Qu.: 8.000 1st Qu.: 8.00
```

```
Mode :character Median :2004 Median : 9.000 Median :16.00
```

```
Mean :2003 Mean : 8.706 Mean :15.73
```

```
3rd Qu.:2013 3rd Qu.: 9.000 3rd Qu.:24.00
```

```
Max. :2022 Max. :12.000 Max. :31.00
```

2. 데이터 다루기 (dplyr 패키지)

hour lat long status

Min. : 0.000 Min. : 7.00 Min. : -136.90 tropical storm :6830

1st Qu.: 5.000 1st Qu.:18.30 1st Qu.: -78.80 hurricane :4803

Median :12.000 Median :26.60 Median : -62.30 tropical depression:3569

Mean : 9.101 Mean :27.01 Mean : -61.56 extratropical :2151

3rd Qu.:18.000 3rd Qu.:33.80 3rd Qu.: -45.50 other low :1453

Max. :23.000 Max. :70.70 Max. : 13.50 subtropical storm : 298

(Other) : 433

2. 데이터 다루기 (dplyr 패키지)

```
category wind pressure tropicalstorm_force_diameter
```

```
Min. :1.000 Min. : 10.00 Min. : 882.0 Min. : 0.0
```

```
1st Qu.:1.000 1st Qu.: 30.00 1st Qu.: 986.0 1st Qu.: 0.0
```

```
Median :1.000 Median : 45.00 Median :1000.0 Median : 110.0
```

```
Mean :1.896 Mean : 50.05 Mean : 993.5 Mean : 147.9
```

```
3rd Qu.:3.000 3rd Qu.: 65.00 3rd Qu.:1007.0 3rd Qu.: 220.0
```

```
Max. :5.000 Max. :165.00 Max. :1024.0 Max. :1440.0
```

```
NA's :14734 NA's :9512
```


2. 데이터 다루기 (dplyr 패키지)

hurricane_force_diameter

Min. : 0.00

1st Qu.: 0.00

Median : 0.00

Mean : 14.92

3rd Qu.: 0.00

Max. : 300.00

NA's : 9512

2. 데이터 다루기 (dplyr 패키지)

```
> storms %>%
+ summarize(
+   평균풍속 = mean(wind),
+   최대값풍속 = max(wind),
+   평균기압 = mean(pressure),
+   최소값기압 = min(pressure),
+   관측치수 = n()
+ )
# A tibble: 1 × 5
  평균풍속 최대값풍속 평균기압 최소값기압 관측치수
  <dbl> <int> <dbl> <int> <int>
1 50.0 165 993. 882 19537
```

2. 데이터 다루기 (dplyr 패키지)

▶ 그룹별 연산 : group_by()

- 특정 변수를 기준으로 데이터를 체계적으로 나누어 분석할 수 있도록 해주는 핵심 기능
- 지정한 변수의 값에 따라 여러 개의 하위 그룹(subgroup)을 형성
- group_by() 안에 데이터 프레임 이름과 기준이 되는 변수를 입력

2. 데이터 다루기 (dplyr 패키지)

예제 4-17 dplyr 패키지에 내장된 tibble 데이터 프레임에서 storms에서 연도(year)별로 풍속(wind)의 평균 구하기

```
> library(dplyr)

> storms %>%
+ group_by(year) %>%
+ summarize(mean_wind = mean(wind))

# A tibble: 48 × 2
year mean_wind
<dbl> <dbl>
1 1975 52.4
2 1976 56.3
3 1977 49.0
4 1978 51.6
```

2. 데이터 다루기 (dplyr 패키지)

```
5 1979 47.9
```

```
6 1980 60.8
```

```
7 1981 51.8
```

```
8 1982 48.6
```

```
9 1983 45
```

```
10 1984 48.4
```

```
# i 38 more rows
```

```
# i Use `print(n = ...)` to see more rows
```

03

실습하기

08강

다음시간안내 ▶▶▶

R 프로그래밍의 핵심구조 (1)