


14강

실전 프로그래밍 1

첨단공학부
정재화 교수





1. 데이터 분석의 이해

- ✓ 빅데이터의 분석 과정
- ✓ 반정형 데이터의 특성

2. 실전 프로그래밍 개요

- ✓ 실전 프로그래밍 과정
- ✓ 웹 스크래핑의 이해
- ✓ 데이터의 저장



학습하기

1

데이터 분석의 이해

빅데이터의 시대

- ICT 기술, 네트워크 서비스의 급격한 발전으로 압도적인 볼륨과 다양한 종류의 데이터가 생성



Legacy Systems



Smart Devices




Social Media



IoT Sensors

빅데이터의 활용 목적

AI: Data-based learning



Big Data: Capture, storage, analysis of data



IoT & ICT : Data Collection through IoT & ICT

빅데이터 분석 과정

실시간 원시 데이터에서 가치를 추출하기 위한 일련의 과정



I 데이터의 유형과 특성

■ 정형 데이터(structured data)

- ✓ 일정한 규칙과 구조를 갖춘 데이터
- ✓ 행과 열의 표 형태로 관계형 데이터베이스에 저장

■ 비정형 데이터(unstructured data)

- ✓ 문장, 음성 등 정해진 구조없이 자유로운 형태의 데이터
- ✓ 분석이 난해↔소비자의 감정, 행동 패턴 등 많은 정보량

■ 반정형 데이터(semi-structured data)

- ✓ 데이터 항목 간 일정한 규칙이나 구조가 존재하나, 완전히 표 형태로 고정 불가능

반정형 데이터의 개념과 특성

- 완전한 정형 데이터는 아니지만
일정한 구조와 규칙을 가진 데이터 유형
 - ✓ 인터넷의 탄생 이후 웹의 기본 구조로 자리잡은 형태
 - ✓ 인터넷상의 거의 모든 정보가 반정형 데이터 형식
- HTML, XML, JSON 등이
대표적인 반정형 데이터 형식
- 웹 데이터 분석,
대규모 언어 모델(LLM) 개발의 훈련 데이터,
데이터 분석/과학 연구 등에 응용

학습하기

2

실전 프로그래밍 개요

실전 프로그래밍 과정

■ 웹 스크래핑 구현 및 텍스트 데이터를 분석

✓ 방송통신대학교 공지사항의 제목을 수집하고 분석

단계	주요 내용
1. 데이터 수집	- Selenium을 활용한 웹 페이지 접근 - lxml을 이용한 HTML 파싱 - 게시글 제목 추출
2. 데이터 전처리	- 정규표현식을 활용한 특수문자 제거 - 형태소 분석을 통한 품사 분리 - 불용어 처리
3. 키워드 분석	- 단어 빈도 분석 - 워드 클라우드 생성

웹 스크래핑 대상 웹사이트

 <https://knou.ac.kr/knou/561/subview.do>

웹 스크래핑 대상 웹사이트

팝업열기 ↓		ENGLISH + 기본 -				
 한국방송통신대학교 KOREA NATIONAL OPEN UNIVERSITY		졸업논문 졸업 대학소개 대학원 입학 학사안내 대학생활 지역대학 해외학생 총장임용추천위원회		로그인	통합검색	☰
1302개 학사안내		공지사항				
번호	제목	작성자	작성일	조회	파일	
	 [수강신청] (프라임칼리지 2026학년도 4월 학점과점) 수강신청 안내	운영지원실	2026-03-12	3482		
	 [일반] [방송대학보] KNOU위클리 282호(2026년 3월 9일 발행) 지면안내	정기간행물(학보)팀	2026-03-09	2822		
	 [시험성적] 2026학년도 1학기 각종 시험 결사사유 인정범위 변경 내용 공지	학사운영과	2026-03-04	7981		
	 [수강신청] [수강신청] 2026학년도 1학기 등록금 납부자의 수강교과목 변경 기간 안내(3.3. 화	학사운영과	2026-03-03	10386		
	 [일반] <증명서 관련> 증명서 발급 불가(26.2.28) 재안내	학생통합서비스센터	2026-02-27	5476		
1802	[장학] 2026년 상반기 군산시 대학생 학자금 이자 지원사업 안내 	학생과	2026.03.12	573		
1801	[일반] 생활 속 목재이용 국민참여 공모전 안내 	학생과	2026.03.12	918		
1800	[일반] 봄철 대규모 행사 참여 관련 학생 안전사고 예방 안내 	학생과	2026.03.12	924		
1799	[수강신청] (프라임칼리지 2026학년도 4월 학점과점) 수강신청 안내 	운영지원실	2026.03.12	3482		
1798	[일반] 2026년 상반기 특수외국어 배워보기 수강신청 안내(국립국제교육원) 	학생과	2026.03.11	4886		
1797	[수업] 2026학년도 1학기 출석수업 강의평가 안내 	학사운영과	2026.03.10	2206		
1796	[일반] (중증 장애인) 2026년 국가공무원 경력경쟁채용시험 안내 	학생과	2026.03.09	2290		
1795	[전공] 2026학년도 2학기 생활과학부 전공분리 신청 안내 	학사운영과	2026.03.09	2636		
1794	[일반] [방송대학보] KNOU위클리 282호(2026년 3월 9일 발행) 지면안내	정기간행물(학보)팀	2026-03-09	2822		

웹 스크래핑(web scrapping)의 이해

■ 프로그램을 통해 웹 사이트에서 데이터를 자동으로 추출하고 수집하는 기술

- ✓ 자동화된 방식으로 웹 페이지를 방문하고 링크를 따라 이동하면서 웹의 구조를 탐색하는 웹 크롤링과 구별

■ 웹 스크래핑 시 고려사항

- ✓ 웹 페이지 구조 분석: 정적 페이지와 동적 페이지
- ✓ 데이터 추출 방법
- ✓ 웹 사이트 정책 준수 여부

■ Selenium, lxml 등 다양한 파이썬 라이브러리를 활용

웹 스크래핑 관련 라이브러리

Selenium

- ✓ 웹 브라우저를 자동화하여 동적 웹 페이지나 로그인이 필요한 페이지에 효과적으로 접근
- ✓ 실제 웹 브라우저를 실행하여 클릭, 입력 등 사용자 행동을 재현

lxml



- ✓ HTML 문서를 파싱하고 원하는 데이터를 추출
- ✓ HTML의 태그와 속성으로 구성된 구조를 해석하고 XPath를 통해 특정 요소를 선택적으로 추출

웹 브라우저의 역할

웹 자원의 형식에 맞게 자원을 가공하여 사용자에게 전달

- ✓ HTML(Hypertext Markup Language)과 같은
언어로 작성된 문서를 처리하여 가시화

```
python - Windows 메모장
파일(F) 편집(E) 서식(O) 보기(V) 도움말
<HTML>
  <HEAD>
    <TITLE> 프라임칼리지 - 파이썬 </TITLE>
  </HEAD>
  <BODY>
    <P>
      <B>파이썬은 재미있습니다.!!!</B>
    </P>
  </BODY>
</HTML>
```



웹 드라이버(Web Driver)

■ 컴퓨터가 웹 브라우저를 직접 제어할 수 있도록
브라우저에 연결할 수 있는 API를 제공

✓ 크롬, 엣지, 파이어폭스 등에서 자체 driver를 제공

Browser	Download Site
크롬	https://googlechromelabs.github.io/chrome-for-testing/
엣지	https://developer.microsoft.com/ko-kr/microsoft-edge/tools/webdriver/
파이어폭스	https://github.com/mozilla/geckodriver/releases
사파리	맥 운영체제 기본 내장으로 다운로드 불필요

I 데이터의 저장

■ 데이터 수집 및 데이터 분석 후

- ✓ 데이터 분석 결과를 다루기 쉬운 형태로 저장
- ✓ 다른 시스템과 공유할 수 있는 과정이 필요

■ Pandas DataFrame은 분석 결과를 활용하는 다양한 기능 제공


- ✓ 최적화된 연산 구조를 갖추고 있어
대용량의 데이터도 빠르고 효율적으로 처리
- ✓ DataFrame에 저장된 데이터를 CSV, JSON,
엑셀, 데이터베이스 등 다른 파일 형식이나
데이터 구조로 변환·저장 가능

Pandas DataFrame의 구조

- 표 형태의 데이터를 다루는 2차원 자료구조
- 표 형태 그 이상으로, 데이터를 효율적으로 처리하고 분석할 수 있도록 설계

	student_id	database_score	cloudcomputing_score	python_score	watch_rate
0	101	85	78	92	0.95
1	102	76	82	78	0.87
2	103	92	95	85	0.99
3	104	63	70	75	0.80
4	105	88	84	91	0.93

다음시간에는



14강. 실전 프로그래밍 1

➡ 15강. 실전 프로그래밍 2