


15강

실전 프로그래밍 2

첨단공학부
정재화 교수





1. 텍스트 데이터 전처리

- ✓ 반정형 데이터 분석 과정
- ✓ 텍스트 정제
- ✓ 형태소 분석

2. 텍스트 데이터 분석

- ✓ 키워드 분석
- ✓ 워드 클라우드 시각화



학습하기

1

텍스트 데이터 전처리

반정형 데이터 분석 과정

■ 텍스트 데이터 전처리

- ✓ 정규표현식을 활용한 특수문자 제거
- ✓ 형태소 분석을 통한 분석 가능한 형태로 정제

■ 키워드 분석

- ✓ 단어 빈도 분석, 워드 클라우드 생성, 주요 키워드 추출을 통해 텍스트 데이터에서 의미 있는 정보를 추출

■ 텍스트 시각화

- ✓ 분류 결과 시각화, 인사이트 도출 과정을 통해 텍스트 데이터의 패턴 발견

텍스트 정제의 개념

■ 텍스트 데이터에서 불필요한 부분을 제거하여 분석에 적합한 형태로 만드는 과정

✓ 불필요한 요소 제거로 분석의 정확도를 향상

■ 수집 데이터

패턴	설명
특수문자 제거	“안녕하세요!^^ 저는 파이썬 개발자입니다.” → “안녕하세요 저는 파이썬 개발자입니다”
대소문자 통일	“Hello World” → “hello world”
HTML 태그 제거	[공지] 기말 성적 → [공지] 기말 성적
불용어 제거	“아니 근데 밥 먹었다.” → “밥 먹었다”

정규표현식의 사용

정규표현식

- ✓ 기호와 문자 조합으로 특정 규칙을 가진 문자열을 탐색
- ✓ 문자 선택, 반복, 문자 범위를 나타내는 요소로 구성

re 표준 라이브러리

- ✓ 정규표현식 처리를 위한 내장 표준 라이브러리

패턴	설명
<code>match(ptn, str)</code>	문자열의 시작부터 패턴이 일치하는지 확인
<code>search(ptn, str)</code>	문자열 전체를 검색하여 패턴과 일치하는 첫 번째 부분 탐색
<code>findall(ptn, str)</code>	패턴과 일치하는 모든 부분을 리스트 형태 반환
<code>sub(ptn, rep, str)</code>	패턴과 일치하는 부분을 다른 문자열로 치환

정규표현식 패턴

요소	설명
[]	대괄호 안에 있는 문자 중 하나 를 매칭
[^...]	대괄호 안에 있는 문자를 제외한 나머지 문자 중 하나 를 매칭
\s	공백 문자(스페이스, 탭, 개행 등)를 매칭
*	앞의 요소가 0번 이상 반복되는 경우를 매칭
+	앞의 요소가 1번 이상 반복되는 경우를 매칭
?	앞의 요소가 0번 또는 1번 나타나는 경우를 매칭
a-z	소문자 알파벳 a부터 z까지의 모든 문자를 매칭
A-Z	대문자 알파벳 A부터 Z까지의 모든 문자를 매칭
0-9	숫자 0부터 9까지의 모든 숫자를 매칭
가-힣	모든 한글 문자를 매칭

주요 패턴	설명
[^a-zA-Z0-9가-힣\s]	영문자, 숫자, 한글, 공백을 제외한 모든 문자
<[^>]*>	<로 시작하고>로 끝나는 모든 HTML 태그
\s+	공백 문자(스페이스, 탭, 개행 등)를 의미

형태소 분석

- 문법적 의미의 최소 단위인 형태소로 텍스트를 분리하고, 각 형태소의 품사를 파악하는 과정
- 교착어인 한국어의 단어가 다양한 어미나 조사와 결합하여 여러 의미를 표현할 수 있어 형태소 분석이 특히 중요
- Kiwi 라이브러리
 - ✓ 한국어 형태소 분석을 위한 최신 도구로, KoNLPy 등 기존 라이브러리보다 빠르고 정확한 분석 결과 제공
 - ✓ 문장의 핵심 의미를 담고 있는 명사를 추출하기 위한 목적으로 사용

학습하기

2

텍스트 데이터 분석


I 키워드 분석

- 텍스트 데이터에서 중요 단어 또는 구문을 추출하고 의미와 패턴을 파악하는 과정
- collections 내장 모듈
 - ✓ 내장 자료형인 리스트, 딕셔너리, 튜플, 세트를 확장하여 더욱 특화되고 효율적인 자료구조를 제공하는 표준 라이브러리
 - ✓ Counter 클래스는 단어의 빈도를 계산하거나 리스트 내 요소의 등장 횟수를 파악할 때 주로 활용

워드 클라우드 시각화

- 텍스트 형태의 빈도 표 등은 데이터의 전체적 패턴을 직관적으로 파악에 한계
- 상대적 빈도차이나 전체적 분포를 한눈에 이해하기 위한 시각화가 필요
- wordcloud 라이브러리
 - ✓ 단어의 등장 빈도에 비례하여 글자의 크기를 다르게 표현하는 시각화 도구
 - ✓ matplotlib 모듈과 연동하여 생성된 워드클라우드 이미지를 화면에 출력하거나 파일로 저장

학생 여러분



한 학기 동안

수고하셨습니다!